

## **Exploratory Data Analysis**

Bootcamp Data Science

#### Kurnia Anwar Ra'if

A Highly-motivated Data Scientist

Senior Data & Al Platform @ PT. Mastersystem Infotama Data Scientist @ PT. KitaLulus International Data Scientist @ PT. Sharing Vision—BRI Consultant Software Engineering @ PT. AlLIMA Geothermal Mentor & Instructor DS/BI/AI ML @ dibimbing.id





#### **Outline**



#### **Outline:**

Exploratory Data Analysis (EDA)

- A. Introduction & Why EDA is important?
- B. Statistical Descriptive: mean, median, mode, and standard deviation
- C. Technique Data Cleaning: Duplicate Data and Missing Data

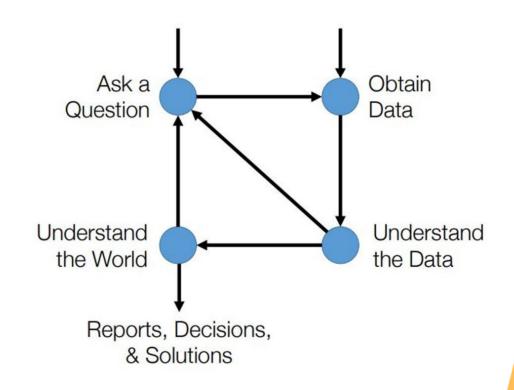
## What is Exploratory Data Analysis (EDA)?

- An exercise to explore the data, to uncover insights from it
  - I.e. to really understand the data
- How exactly to do the "exploration"?
  - Essentially by looking at various angles of the data
- In today's session, we will learn several standard techniques to perform EDA



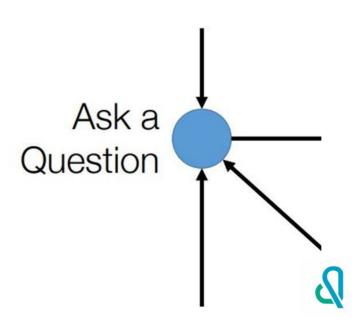


Data Science Process

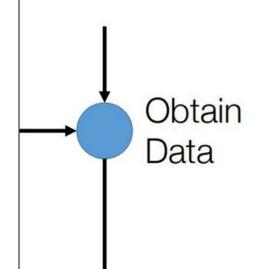


#### Question / Problem Formulation

- What do we want to know?
- What problems are we trying to solve?
- What are the hypotheses we want to test?
- What are our metrics of success?

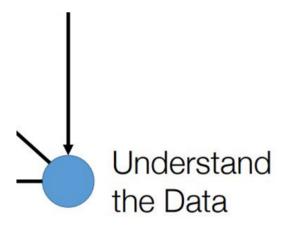


#### Data Acquisition and Cleaning



- What data do we have and what data do we need?
- How will we sample more data?
- Is our data representative of the population we want to study?





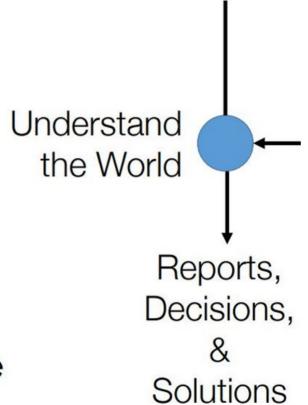
- How is our data organized and what does it contain?
- What are the biases, anomalies, or other issues with the data?
- How do we transform the data to enable effective analysis?

Exploratory Data Analysis & Visualization



- What does the data say about the world?
- Does it answer our questions or accurately solve the problem?
- How robust are our conclusions and can we trust the predictions?

Predictions and Inference





Statistical Descriptive: mean, median, mode, and standard deviation



#### 1 MEAN

Rata-rata adalah penjumlahan dari setiap nilai dibagi dengan banyaknya data.

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n} = \frac{X_1 + X_2 + \dots + X_n}{n}$$



## 1 MEAN

#### **Contoh:**

Kita memiliki data nilai mahasiswa sebagai berikut

5,5,6,7,7,7,9,9,10

Carilah mean dari data berikut.



## 1 MEAN

#### Sifat Rata-rata (Mean)

Rata-rata sangat terpengaruh oleh nilai yang sangat besar sekali atau kecil sekali.

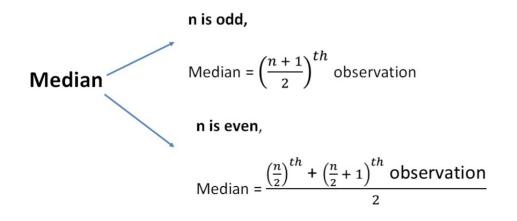
Nilai ini biasa disebut dengan <u>outliers</u>. **Tidak disarankan untuk menggunakan rata-rata apabila terdapat outliers pada data kita.** 

Sifat ini dinamakan not robust



### 2 MEDIAN

Median adalah nilai tengah data yang terletak di urutan ke-50% dari keseluruhan data jika data telah diurutkan dari yang terkecil ke terbesar





## <sup>2</sup> MEDIAN

#### **Contoh:**

Kita memiliki data nilai mahasiswa sebagai berikut

5,5,6,7,7,7,9,9,10

Carilah mean dari data berikut.

Banyaknya data = 10 (genap)  
Median = 
$$(x-5 + x-6)/2$$
  
=  $(7+7)/2 = 7$ 



## <sup>2</sup> MEDIAN

#### **Sifat Median**

Median relatif **robust** terhadap outlier (tidak terpengaruh oleh nilai yang sangat tinggi atau rendah)

Biasanya digunakan untuk **distribusi skew** (menceng kiri/kanan)



**3 MODUS** 

Modus adalah data yang paling sering muncul/ memiliki frekuensi paling tinggi.





## 2 MODUS

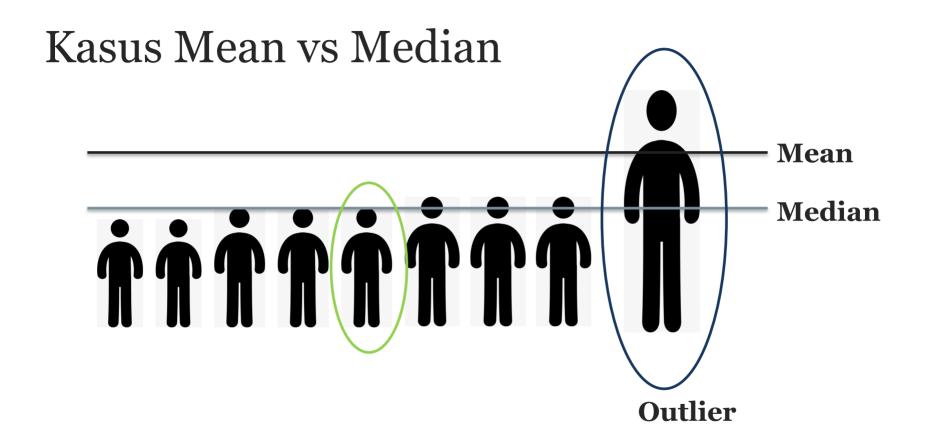
#### **Sifat Modus**

Modus biasa digunakan untuk **data yang bertipe kategorikal** (bukan data numerik)

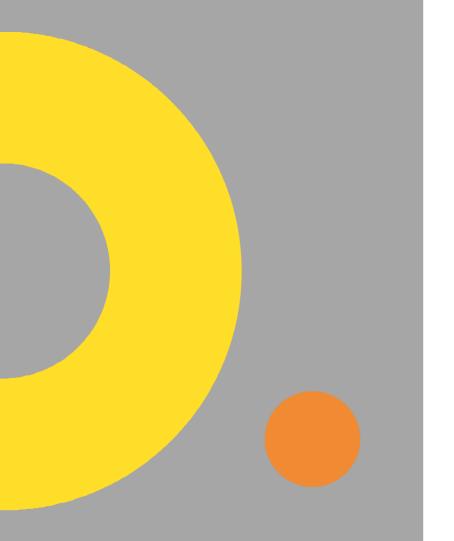
#### Contoh:

Gender = [F, F, M, M, M, F, M, F, F, F, F] **Modus** = **F** 









Variansi, Standar deviasi, Kovariansi, dan Korelasi



#### Variansi dan Standar deviasi

#### 1 VARIANSI

- Rata-rata kuadrat selisih setiap data dari mean
- Mengukur persebaran dari sebuah data

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$$

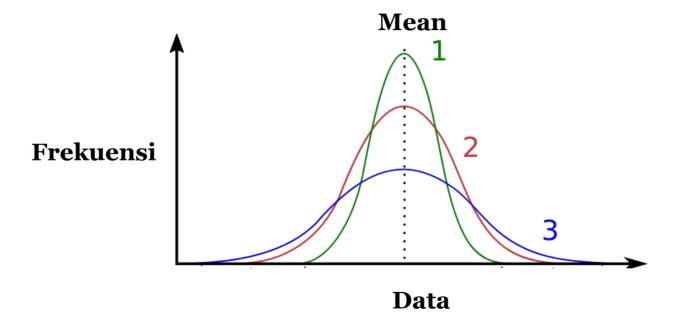
#### 2 STANDAR DEVIASI

- Akar dari variansi (agar skalanya sebanding dengan data asal)
- Mengukur persebaran dari sebuah data

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

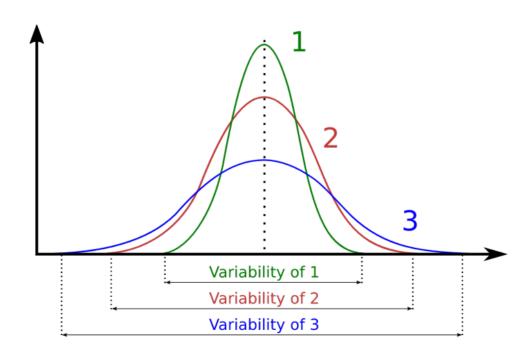


#### Variansi dan Standar deviasi

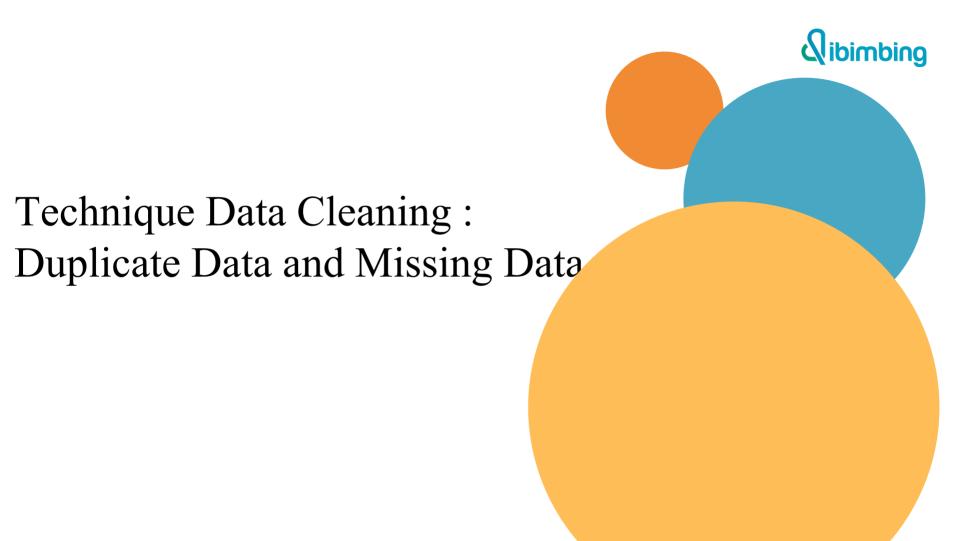




#### Variansi dan Standar deviasi





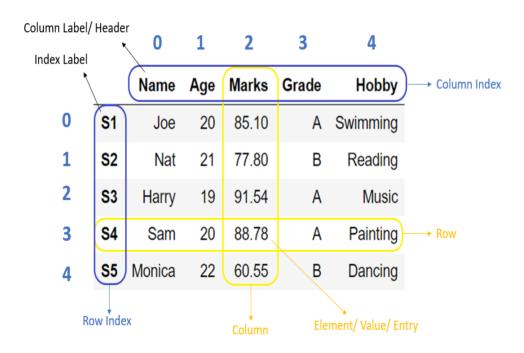


## **Data Frame**



#### THE PANDAS DATAFRAME

Pandas adalah library dasar yang digunakan untuk melakukan manipulasi pada data frame. Data Frame adalah tabel/data tabular dengan array dua dimensi yaitu baris dan kolom.



## Handle Duplikat

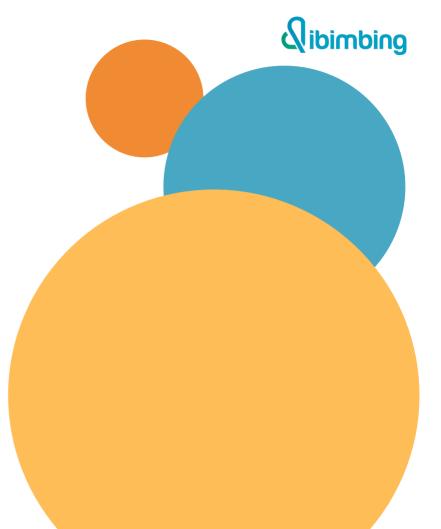
Machine Learning tidak bisa memproses data yang duplikat:

	pclass	survived	name s	ex age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
104	1	1	Eustis, Miss. Elizabeth Mussey fem	ale 54.0	1	0	36947	78.2667	D20	С	4	NaN	Brookline, MA
349	1	1	Eustis, Miss. Elizabeth Mussey fem	ale 54.0	1	0	36947	78.2667	D20	С	4	NaN	Brookline, MA

Maka harus dipilih salah satunya saja -> Handling Duplikat



# Handling Missing Value





Terdapat berbagai cara untuk merepresentasikan data yang hilang atau nilai yang tidak sesuai didalam data.

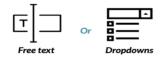
df_company.sample(5)

	Revenue	Size	Rating	Headquarters
512	2to5 billion (USD)	5001 to 10000 employees	3.5	Westminster, CO
521	10to25 million (USD)	51 to 200 employees	3.8	Arlington, VA
330	100to500 million (USD)	501 to 1000 employees	3.7	Lorton, VA
517	Unknown / Non-Applicable	51 to 200 employees	2.7	Chantilly, VA
129	2to5 billion (USD)	5001 to 10000 employees	NaN	Sunnyvale, CA

Missing values are treated as np.NaN when data is not read into Pandas

Missing values are treated as np.NaN when data is read into Pandas

Mengapa bisa ada missing value?



Data Entry Errors

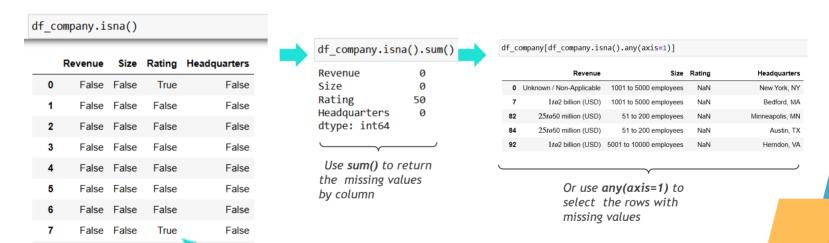


**Parsing Errors** 

#### **IDENTIFYING MISSING DATA**

Cara paling mudah untuk mengidentifikasi data yang hilang adalah dengan menggunakan :

- metode .isna().
- Juga dapat menggunakan.value\_counts().



This returns **True** for any missing values

#### Flow Handling Missing Value

- 1. Cek terlebih dahulu, nilai unik di tiap kolom. Kemudian cek berapa persen missing value tiap kolom. Secara Statistik jika > 20% maka drop kolomnya, jika dibawah itu maka handling dengan cara:
- 2. Jika numerikal kolom maka handle menggunakan nilai median dari data train, lalu aplikasikan ke data train dan ke data test di kolom bersangkutan.
- 3. Jika kolom **kategorikal** maka handle menggunakan nilai **modus** dari data train, lalu aplikasikan ke data train dan ke data test di kolom bersangkutan.



## Hands on!



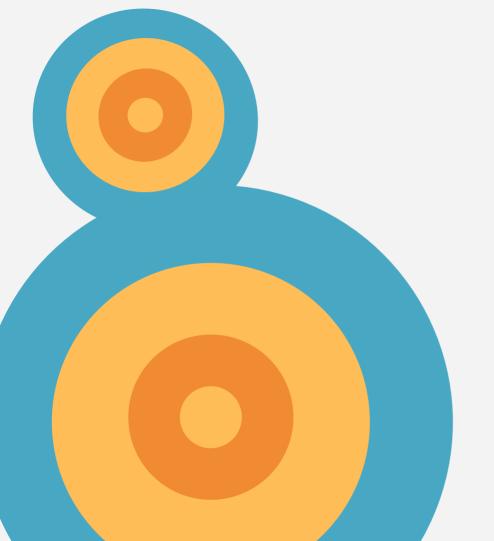
## Assignment:

Jawablah pertanyaan pada template code dan cek link berikut : <a href="https://drive.google.com/drive/folders/">https://drive.google.com/drive/folders/</a> <a href="mailto:linkbzvoYfwn6RMm7MSIA3wl7n59JXNNj">lmkBzvoYfwn6RMm7MSIA3wl7n59JXNNj</a>

**B?usp=sharing** 







## Thank you

in

https://www.linkedin.com/in/anwaraif/

M

kurniafreelancer@gmail.com